Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное
образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ _Информатика и системы управления_____

КАФЕДРА __Системы обработки информации и управления (ИУ5)_____

ОТЧЕТ
по лабораторной работе

«Ансамбли моделей машинного обучения.»

ДИСЦИПЛИНА: «Технологии машинного обучения»

Выполнил: студент гр. _ИУ5-62Б_ _____ (____Кудрявцев С.Д.___)
(Подпись) (Ф.И.О.)

Проверил: _____ (____Гапанюк Ю.Е.___)
(Подпись) (Ф.И.О.)

2020 г.

Лабораторная работа №6

Ансамбли моделей машинного обучения

Цель лабораторной работы

Изучение ансамблей моделей машинного обучения.

Задание

- Выберите набор данных (датасет) для решения задачи классификации или регресии.
- В случае необходимости проведите удаление или заполнение пропусков и кодирован
- С использованием метода train_test_split разделите выборку на обучающую и тестову
- Обучите две ансамблевые модели. Оцените качество моделей с помощью одной из п
  качество полученных моделей.

Ход выполнения лабораторной работы

```
import pandas as pd
import seaborn as sns
import numpy as np
import matplotlib.pyplot as plt
from sklearn.preprocessing import MinMaxScaler
from sklearn.model_selection import train_test_split
from sklearn.metrics import f1_score, precision_score, recall_score, accuracy_scor
from sklearn.ensemble import RandomForestClassifier
from sklearn.ensemble import GradientBoostingClassifier
%matplotlib inline
sns.set(style="ticks")


col_list = ['Pelvic_incidence',
               'Pelvic_tilt',
               'Lumbar_lordosis_angle',
               'Sacral_slope',
               'Pelvic_radius',
               'Degree_spondylolisthesis',

               'Pelvic_slope',
               'Direct_tilt',
               'Thoracic_slope',
               'Cervical_tilt',
               'Sacrum_angle',
               'Scoliosis_slope',
               'Class_att',
               'To drop']
```

```
data = pd.read_csv('data/Dataset_spine.csv', names=col_list, header=1, sep=",")
data.drop('To_drop', axis=1, inplace=True)
```

```
data.head()
```

	Pelvic_incidence	Pelvic_tilt	Lumbar_lordosis_angle	Sacral_slope	Pelvic_
0	39.056951	10.060991	25.015378	28.995960	114.
1	68.832021	22.218482	50.092194	46.613539	105.
2	69.297008	24.652878	44.311238	44.644130	101.
3	49.712859	9.652075	28.317406	40.060784	108.
4	40.250200	13.921907	25.124950	26.328293	130.

```
data.isnull().sum()
```

```
Pelvic_incidence            0
Pelvic_tilt                 0
Lumbar_lordosis_angle       0
Sacral_slope                0
Pelvic_radius               0
Degree_spondylolisthesis    0
Pelvic_slope                0
Direct_tilt                 0
Thoracic_slope              0
Cervical_tilt               0
Sacrum_angle                0
Scoliosis_slope             0
Class_att                   0
dtype: int64
```

Пропуски данных отсутствуют.

```
#Кодирование категориальных признаков
data['Class_att'] = data['Class_att'].map({'Abnormal': 1, 'Normal': 0})
```

В качестве метрики для решения задачи классификации будем использовать: Pr
классификатором положительных объектов, из всех объектов, которые классифи
как положительные.

Разработаем класс, который позволит сохранять метрики качества построенных моделей качества.

```
class MetricLogger:
```

```
    def __init__(self):
        self.df = pd.DataFrame(
            {'metric': pd.Series([], dtype='str'),
            'alg': pd.Series([], dtype='str'),
            'value': pd.Series([], dtype='float')})

    def add(self, metric, alg, value):
        """
        Добавление значения
        """
        # Удаление значения если оно уже было ранее добавлено
        self.df.drop(self.df[(self.df['metric']==metric)&(self.df['alg']==alg)].in
        # Добавление нового значения
        temp = [{'metric':metric, 'alg':alg, 'value':value}]
        self.df = self.df.append(temp, ignore_index=True)

    def get_data_for_metric(self, metric, ascending=True):
        """
        Формирование данных с фильтром по метрике
        """
        temp_data = self.df[self.df['metric']==metric]
        temp_data_2 = temp_data.sort_values(by='value', ascending=ascending)
        return temp_data_2['alg'].values, temp_data_2['value'].values

    def plot(self, str_header, metric, ascending=True, figsize=(5, 5)):
        """
        Вывод графика
        """
        array_labels, array_metric = self.get_data_for_metric(metric, ascending)
        fig, ax1 = plt.subplots(figsize=figsize)
        pos = np.arange(len(array_metric))
        rects = ax1.barh(pos, array_metric,
                         align='center',
                         height=0.5,
                         tick_label=array_labels)
        ax1.set_title(str_header)
        for a,b in zip(pos, array_metric):
            plt.text(0.5, a-0.05, str(round(b,3)), color='white')
        plt.show()
```

Для задачи классификации будем использовать случайный лес и градиентный бустинг.

Формирование обучающей и тестовой выборок

```
data.columns
```

```
Index(['Pelvic_incidence', 'Pelvic_tilt', 'Lumbar_lordosis_angle',
       'Sacral_slope', 'Pelvic_radius', 'Degree_spondylolisthesis',
       'Pelvic_slope', 'Direct_tilt', 'Thoracic_slope', 'Cervical_tilt',
       'Sacrum_angle', 'Scoliosis_slope', 'Class_att'],
      dtype='object')
```

```
data.dtypes
```

```
data.dtypes
```

```
Pelvic_incidence            float64
Pelvic_tilt                 float64
Lumbar_lordosis_angle       float64
Sacral_slope                float64
Pelvic_radius               float64
Degree_spondylolisthesis    float64
Pelvic_slope                float64
Direct_tilt                 float64
Thoracic_slope              float64
Cervical_tilt               float64
Sacrum_angle                float64
Scoliosis_slope             float64
Class_att                     int64
dtype: object
```

```
# Признаки для задачи классификации
class_cols = ['Pelvic_incidence',
              'Pelvic_tilt',
              'Lumbar_lordosis_angle',
              'Degree_spondylolisthesis',
              ]


X = data[class_cols]
Y = data['Class_att']
X.shape
```

```
(309, 4)
```

```
# С использованием метода train_test_split разделим выборку на обучающую и тестову
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.25, random_s


X_train.shape, X_test.shape, Y_train.shape, Y_test.shape
```

```
((231, 4), (78, 4), (231,), (78,))
```

Обучение моделей

```
# Сохранение метрик
clasMetricLogger = MetricLogger()


def train_model(model_name, model, MetricLogger):
    model.fit(X_train, Y_train)

    Y_pred = model.predict(X_test)
    precision = precision_score(Y_test.values, Y_pred)

    MetricLogger.add('precision', model_name, precision)

    print('**************************************************')
    print(model_name)
```

```
    print(model_name)
    print(model)
    print("precision_score:", precision)


train_model('Случайный лес', RandomForestClassifier(), clasMetricLogger)
train_model('Градиентный бустинг', GradientBoostingClassifier(), clasMetricLogger)
```

```
    **********************************************************
    Случайный лес
    RandomForestClassifier(bootstrap=True, ccp_alpha=0.0, class_weight=None,
                           criterion='gini', max_depth=None, max_features='auto',
                           max_leaf_nodes=None, max_samples=None,
                           min_impurity_decrease=0.0, min_impurity_split=None,
                           min_samples_leaf=1, min_samples_split=2,
                           min_weight_fraction_leaf=0.0, n_estimators=100,
                           n_jobs=None, oob_score=False, random_state=None,
                           verbose=0, warm_start=False)
    precision_score: 0.8363636363636363
    **********************************************************
    Градиентный бустинг
    GradientBoostingClassifier(ccp_alpha=0.0, criterion='friedman_mse', init=None,
                               learning_rate=0.1, loss='deviance', max_depth=3,
                               max_features=None, max_leaf_nodes=None,
                               min_impurity_decrease=0.0, min_impurity_split=None,
                               min_samples_leaf=1, min_samples_split=2,
                               min_weight_fraction_leaf=0.0, n_estimators=100,
                               n_iter_no_change=None, presort='deprecated',
                               random_state=None, subsample=1.0, tol=0.0001,
                               validation_fraction=0.1, verbose=0,
                               warm_start=False)
```

Оценка качества моделей

```
# Метрики качества модели
clas_metrics = clasMetricLogger.df['metric'].unique()
clas_metrics
```

```
    array(['precision'], dtype=object)
```

```
# Построим графики метрик качества модели
for metric in clas_metrics:
    clasMetricLogger.plot('Метрика: ' + metric, metric, figsize=(5, 3))
```

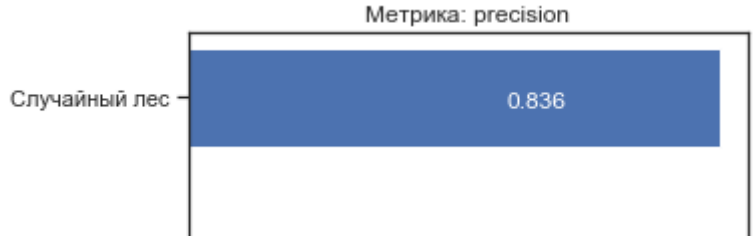

На основании метрики precision лучшим оказался случайный лес.